Rapport 1 - Projet Image : Anonymisation

Les débuts du projet

Rémi Bonnafé, Mickaël Longlade, et Killian Texier-Grailhes

I. État de l'art 1
1. Article de référence : RiDDLE [1] 1
2. Encodeur : ArcFace [2] 1
3. Auto-encodeur : Live Face De-Identification in Video [3] 2
4. GAN : CIAGAN [4] 3
II. Suite du projet 4
III. Bibliographie 4

I. État de l'art

On va tout d'abord regarder l'article de référence pour voir l'objectif final, puis on regardera un article pour chacune des trois briques que l'on doit développer dans le projet : l'**encodeur**, l'**auto-encodeur** et le **GAN**. Tous les articles qui suivent sont cités dans l'article de référence.

1. Article de référence : RiDDLE [1]

Le titre nous donne déjà beaucoup d'informations : **Reversible and Diversified De-identification with Latent Encryptor** signifie, pris littéralement, une dé-identification réversible et diversifiée avec un chiffreur latent.

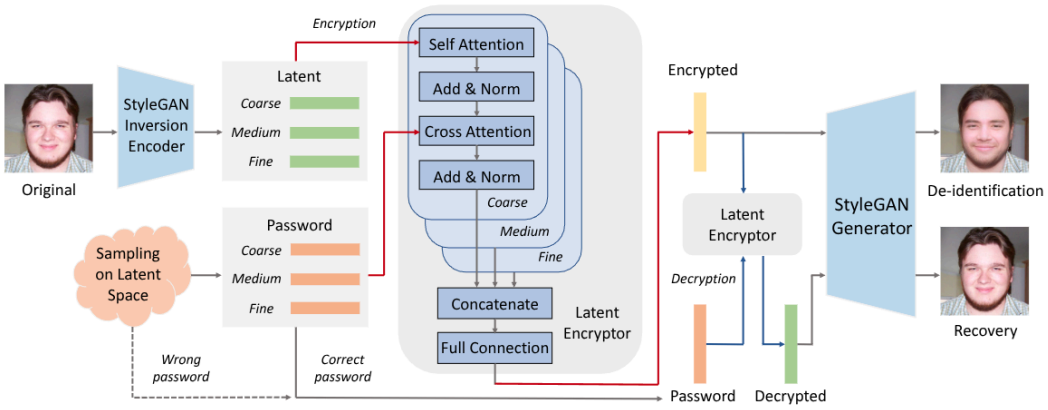


Figure 2. The overall pipeline of our method. We take the correct decryption process as an example, where the same password is used for both encryption and decryption.

Fig. 1. – Pipeline complet de la méthode **RiDDLE**.

On peut observer sur la Fig. 1 toutes les étapes permettant d'**anonymiser** et de **désanonymiser** un visage. Voici ces étapes :

1. un **encodeur** d'inversion projette l'image dans un espace latent de StyleGAN2 ;
2. le **latent encryptor**, qui va combiner le code latent obtenu plus tôt avec un **mot de passe**, afin de rendre l'anonymisation réversible (ce mot de passe est lui aussi issu d'un espace latent) ;
3. le **générateur** StyleGAN2, qui va créer un nouveau visage à partir du code latent chiffré.

À noter que, dans cette méthode, seul le **latent encryptor** est entraîné : l'encodeur d'inversion et le générateur StyleGAN2 sont pré-entraînés.

2. Encodeur : ArcFace [2]

ArcFace est un réseau de **reconnaissance faciale** : il transforme un visage en un vecteur de 512 valeurs. Deux photos de la même personne donnent des vecteurs proches. Attention, ce n'est pas l'encodeur d'inversion de RiDDLE (e4e), qui projette l'image dans l'espace latent de StyleGAN2 : ArcFace est un encodeur d'**identité**.

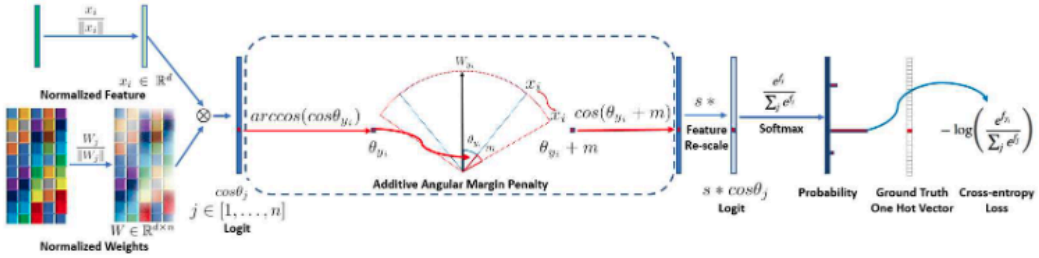


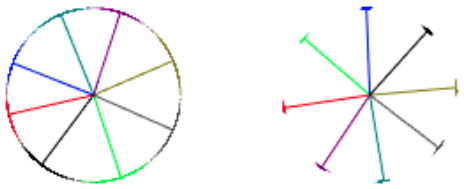
Figure 2. Training a DCNN for face recognition supervised by the ArcFace loss. Based on the feature x_i and weight W normalisation, we get the $\cos\theta_j$ (logit) for each class as $W_j^T x_i$. We calculate the $arccos\theta_{y_i}$ and get the angle between the feature x_i and the ground truth weight W_{y_i}. In fact, W_j provides a kind of centre for each class. Then, we add an angular margin penalty m on the target (ground truth) angle θ_{y_i}. After that, we calculate $\cos(\theta_{y_i} + m)$ and multiply all logits by the feature scale s. The logits then go through the softmax function and contribute to the cross entropy loss.

Fig. 2. – Entraînement d'un réseau de reconnaissance faciale avec **ArcFace**.

Le réseau est entraîné à classer des identités (Fig. 2). L'idée d'ArcFace est d'ajouter une marge m à l'angle θ_y entre le visage et sa bonne classe y :

$$\mathcal{L} = -\log \frac{e^{s\cos(\theta_y+m)}}{e^{s\cos(\theta_y+m)} + \sum_{j\neq y} e^{s\cos\theta_j}}$$

où $\mathcal{L}$ est la perte à minimiser, θ_j l'angle entre le vecteur du visage et celui de la classe j, et s un facteur d'échelle fixe. Cette marge oblige les identités à être bien séparées (Fig. 3).



(a) Softmax (b) ArcFace

Figure 3. Toy examples under the softmax and ArcFace loss on 8 identities with 2D features. Dots indicate samples and lines refer to the centre direction of each identity. Based on the feature normalisation, all face features are pushed to the arc space with a fixed radius. The geodesic distance gap between closest classes becomes evident as the additive angular margin penalty is incorporated.

Fig. 3. – 8 identités en 2D : softmax classique à gauche, **ArcFace** à droite.

Ce réseau est utilisé dans la méthode **RiDDLE** afin de vérifier que le visage anonymisé ne ressemble pas au visage original, et sert surtout à entraîner le **latent encryptor**.

3. Auto-encodeur : Live Face De-Identification in Video [3]

Cette méthode anonymise des visages dans des vidéos, en temps réel, avec un **auto-encodeur** entraîné de bout en bout. Contrairement à RiDDLE, il n'y a pas de StyleGAN pré-entraîné : le réseau apprend lui-même à décoder le visage. Il en sort deux choses : un nouveau visage et un **masque**, qui sert à le fusionner avec l'image d'origine pour ne pas redessiner le fond (Fig. 4).

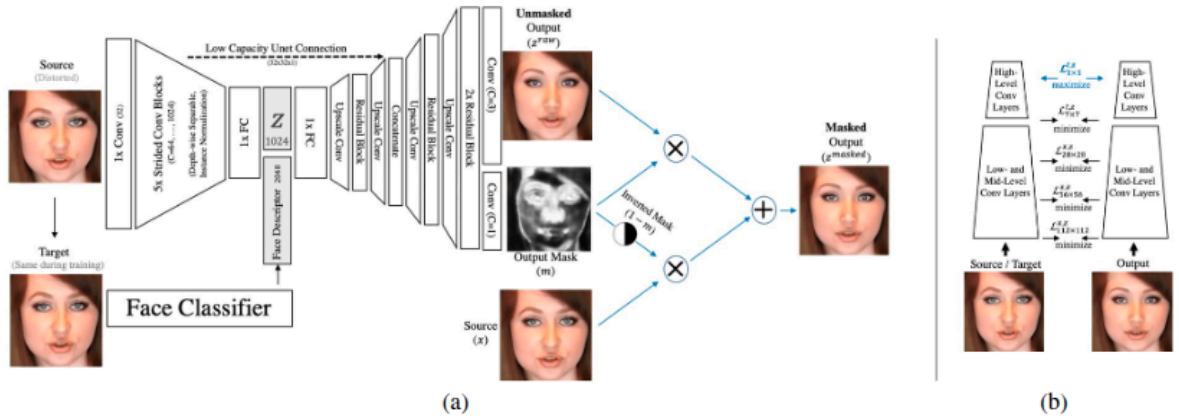


Figure 2. (a) The architecture of our network. For conditioning, a pre-trained face recognition network is used. (b) An illustration of the multi-image perceptual loss used, which employs two replicas of the same face recognition network.

Fig. 4. – Architecture de l'auto-encodeur de Gafni *et al.*

Pour enlever l'identité, elle utilise une perte avec un réseau de reconnaissance faciale :

- ses **premières couches** (pose, expression, éclairage) doivent rester proches de l'original ;
- ses **dernières couches** (l'identité) doivent s'en éloigner.

Le visage change donc de personne, mais garde la même attitude (Fig. 5). En revanche, cette méthode n'est pas réversible et ne donne qu'un seul résultat par visage.



Figure 1. De-identification video results demonstrated on a variety of poses, expressions, illumination conditions and occlusions. Pairs of the source frame (first row) and the output frame (second row) are shown. The high-level features (e.g. nose, eyes, eyebrows and mouth) are altered, while the pose, expression, lip articulation, illumination, and skin tone are preserved.

Fig. 5. – Image source (en haut) et image anonymisée (en bas).

4. GAN : CIAGAN [4]

CIAGAN est un GAN **conditionnel**. Le générateur reçoit l'image avec le visage masqué, les **landmarks** (les points clés du visage) et une **identité cible**, puis il dessine un nouveau visage. Deux discriminateurs l'entraînent : l'un vérifie que l'image est réaliste, l'autre qu'elle a bien l'identité cible (Fig. 6).

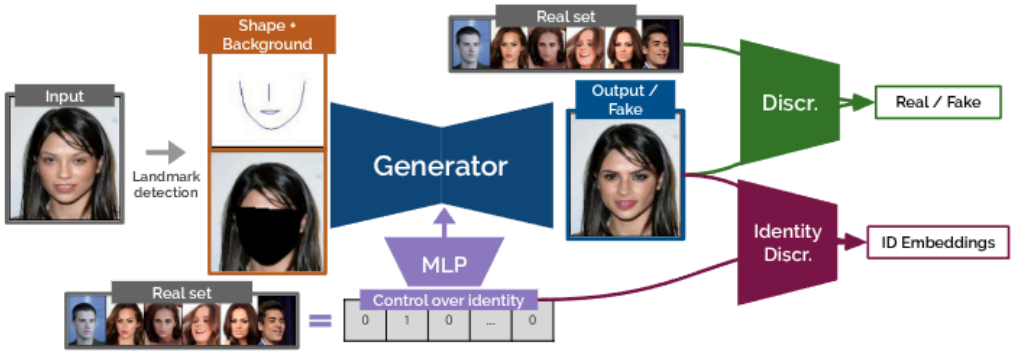


Figure 2: Our CIAGAN model takes as input the image, its landmark, the masked face and the desired identity. The generator is an encoder-decoder model where the encoder embeds the image information into a low dimensional space. The identity given as a one-hot label is encoded via a transposed convolutional neural network and is fed in the bottleneck of the generator. Then the decoder decodes the combined information of source images and the identities into a generated image. The generator plays an adversarial game with a discriminator in a standard GAN-setting. Finally, we introduce an identity discriminator network, whose goal is to provide a guiding signal to the generator about the desired identity of the generated face.

Fig. 6. – Architecture de **CIAGAN**.

Ainsi, en changeant l'identité cible, on obtient des visages différents (Fig. 7).

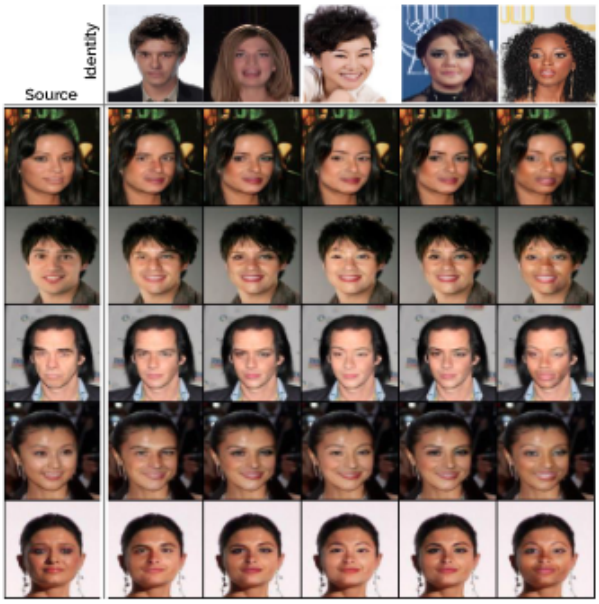


Figure 3: Generated faces of our model, where a source image is anonymized based on different identities.

Fig. 7. – Un même visage anonymisé avec plusieurs identités cibles.

II. Suite du projet

Pour la semaine prochaine, on compte commencer l'implémentation d'un **encodeur** en Python. C'est le langage le plus utilisé et le mieux documenté pour les réseaux de neurones, et c'est celui du code de RiDDLE et des modèles pré-entraînés qu'il utilise (ArcFace, StyleGAN2).

III. Bibliographie

[1] D. Li, W. Wang, K. Zhao, J. Dong, et T. Tan, « RiDDLE: Reversible and Diversified De-identification with Latent Encryptor », 2023. [En ligne]. Disponible sur: https://arxiv.org/pdf/2303.05171

[2] J. Deng, J. Guo, N. Xue, et S. Zafeiriou, « ArcFace: Additive Angular Margin Loss for Deep Face Recognition », 2019. [En ligne]. Disponible sur: https://openaccess.thecvf.com/content_CVPR_2019/papers/Deng_ArcFace_Additive_Angular_Margin_Loss_for_Deep_Face_Recognition_CVPR_2019_paper.pdf

[3] O. Gafni, L. Wolf, et Y. Taigman, « Live Face De-Identification in Video », 2019. [En ligne]. Disponible sur: https://openaccess.thecvf.com/content_ICCV_2019/papers/Gafni_Live_Face_De-Identification_in_Video_ICCV_2019_paper.pdf

[4] M. Maximov, I. Elezi, et L. Leal-Taixé, « CIAGAN: Conditional Identity Anonymization Generative Adversarial Networks », 2020. [En ligne]. Disponible sur: https://arxiv.org/pdf/2005.09544