Rapport 2 - Projet Image : Anonymisation

Prise en main de RiDDLE

Rémi Bonnafé, Mickaël Longlade, et Killian Texier-Grailhes

I. Ce qu'on a fait cette semaine 1
II. Ce que RiDDLE fait bien 1
III. Ce que RiDDLE fait moins bien 2
IV. Objectifs pour la suite 3
V. Bibliographie 4

I. Ce qu'on a fait cette semaine

On a fait tourner le code de **RiDDLE** [1] : mise à jour de l'environnement, récupération des poids pré-entraînés, et un script qui aligne et inverse (avec e4e) nos propres photos. On l'a testé sur des visages de FFHQ et sur 4 photos à nous.

Pour mesurer l'identité, on utilise la similarité cosinus entre vecteurs ArcFace [2] (1 = même personne) :

Visages comparés	**Similarité**
Original / inversion e4e	0,83
Original / chiffré	0,02
Original / déchiffré (bon mot de passe)	0,73
Original / déchiffré (mauvais mot de passe)	0,12
Deux personnes différentes (originaux)	0,10
Même personne, deux mots de passe (chiffrés)	0,13
Deux personnes, même mot de passe (chiffrés)	**0,60**

Tableau 1. – Similarité ArcFace moyenne (3 personnes, 5 mots de passe).

Ces chiffres restent indicatifs : peu de visages, et ArcFace est aussi utilisé pour entraîner RiDDLE.

II. Ce que RiDDLE fait bien

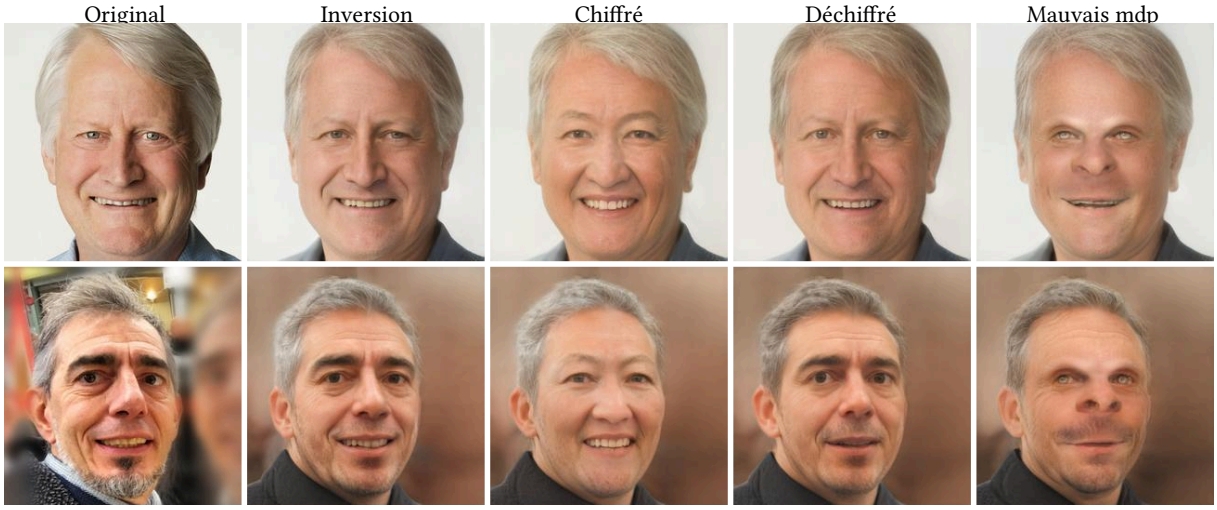


Fig. 1. – RiDDLE sur deux de nos photos.

- **Identité effacée** : 0,02 entre l'original et le visage chiffré.
- **Attributs conservés** : pose, expression, coiffure, vêtements, fond (Fig. 1).
- **Réalisme** avec le bon mot de passe.
- **Réversible** (0,73) et **diversifié** : deux mots de passe donnent deux identités distinctes (Fig. 2).
- **Rapide** : seul le **latent encryptor** est entraîné, ~6 s pour 8 visages.

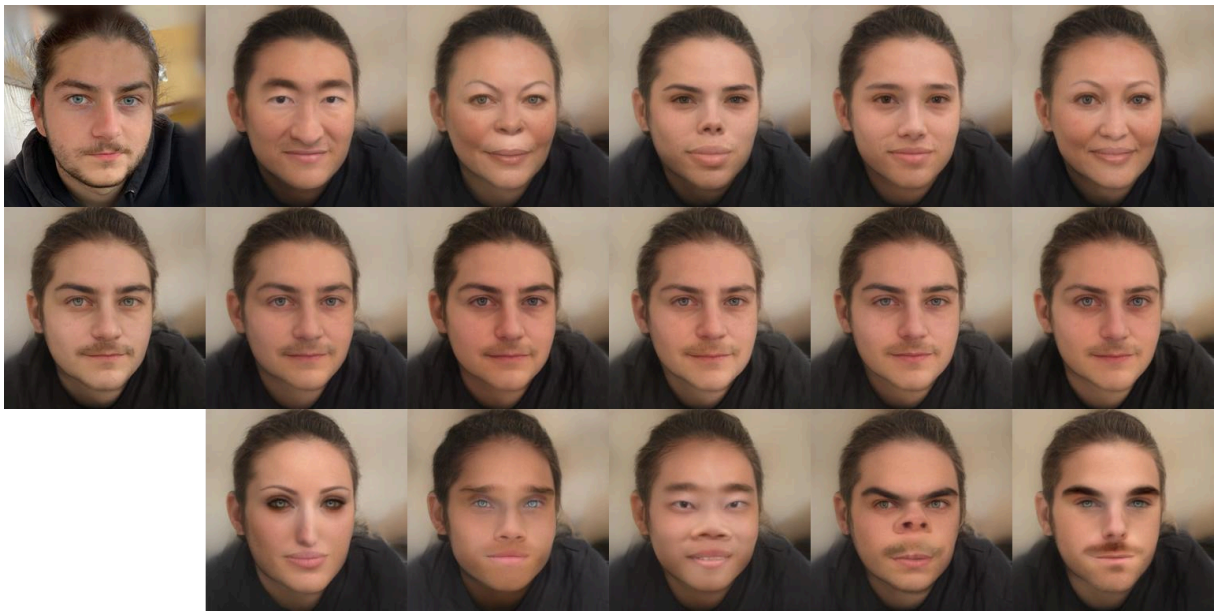


Fig. 2. – Un visage, 5 mots de passe. Lignes : chiffré, déchiffré (bon mot de passe), déchiffré (mauvais mot de passe).

III. Ce que RiDDLE fait moins bien

- **Mauvais mot de passe → visages irréalistes** : yeux jaunes, nez gonflé, traits « collés » (dernière ligne de la Fig. 2). Le chiffreur est appliqué deux fois, ce qui sort le code latent de la zone réaliste de StyleGAN2, et RiDDLE n'a **pas de discriminateur** pour l'en empêcher.
- **Un mot de passe → presque le même visage pour tous** (0,60, Fig. 3). La perte de diversité sépare les mots de passe, pas les personnes : une base anonymisée avec un seul mot de passe ne permet plus de distinguer les gens.
- **Âge, genre et origine non conservés** : un bébé devient une femme adulte (Fig. 4).
- **Inversion e4e imparfaite** (0,83) : le fond, la barbe et la texture de peau sont perdus, donc le déchiffrement ne redonne jamais la photo exacte.
- **Autres limites** : cheveux, vêtements et fond restent reconnaissables ; le visage (256×256, aligné) n'est pas réinséré dans la photo ; la détection rate les profils.



Fig. 3. – Trois de nos photos (haut) chiffrées avec le **même** mot de passe (bas).

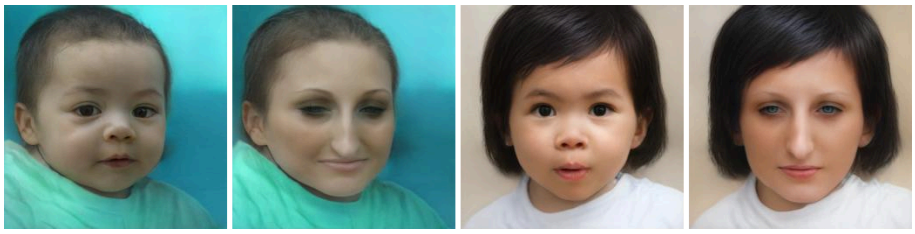


Fig. 4. – Deux enfants de FFHQ et leur version chiffrée.

IV. Objectifs pour la suite

1. **Évaluer** avec un autre réseau de reconnaissance faciale, sur plus de visages (partie **encodeur**).
2. **Ajouter un discriminateur** sur les visages chiffrés et mal déchiffrés pour garantir leur réalisme (partie **GAN**).
3. **Séparer les personnes** : une perte qui éloigne les visages chiffrés de personnes différentes avec le même mot de passe.
4. **Conserver l'âge et le genre** via un classifieur.
5. **Réinsérer le visage** dans la photo avec un masque, comme Gafni *et al.* [3] (partie **auto-encodeur**).

Les deux premiers points sont prioritaires.

V. Bibliographie

[1] D. Li, W. Wang, K. Zhao, J. Dong, et T. Tan, « RiDDLE: Reversible and Diversified De-identification with Latent Encryptor », 2023. [En ligne]. Disponible sur: https://arxiv.org/pdf/2303.05171

[2] J. Deng, J. Guo, N. Xue, et S. Zafeiriou, « ArcFace: Additive Angular Margin Loss for Deep Face Recognition », 2019. [En ligne]. Disponible sur: https://openaccess.thecvf.com/content_CVPR_2019/papers/Deng_ArcFace_Additive_Angular_Margin_Loss_for_Deep_Face_Recognition_CVPR_2019_paper.pdf

[3] O. Gafni, L. Wolf, et Y. Taigman, « Live Face De-Identification in Video », 2019. [En ligne]. Disponible sur: https://openaccess.thecvf.com/content_ICCV_2019/papers/Gafni_Live_Face_De-Identification_in_Video_ICCV_2019_paper.pdf